2026

Fundamentos de la Ciencia de Datos

Trabajo Práctico Especial

Grupo 4
Gonzalez Barboza, Ignacio
Nucciarone Dimuro, Mateo
Murgades, Faustino

Dataset: Cuarta Encuesta Nacional de Factores de Riesgo (ENFR 2018) · Profesora a cargo: Rosana Cepeda

1. Introducción

1.1. El problema

Las enfermedades crónicas (hipertensión, diabetes, obesidad, enfermedades cardiovasculares) se buscan explicar por factores de riesgo que se pueden medir y, en teoría, modificar: tabaco, alcohol, alimentación, sedentarismo y peso corporal. Saber cuánta gente tiene esos hábitos y cómo se relacionan con las enfermedades es la base para diseñar políticas de prevención. En este trabajo nos propusimos investigar: qué hábitos tiene la población adulta argentina y qué tanto se asocian con las enfermedades previamente mencionadas.

1.2. Problemas que encontramos y cómo los resolvimos

- **Demasiadas variables.** Con 287 columnas era imposible mirar todo junto. Dividimos la base por bloques del cuestionario (Hogar y Ubicación e Individual) y por temática, y después elegimos sólo las variables que necesitaba cada hipótesis (Sec. 1.1 y 1.2 del notebook).
- **Vacíos que no son faltantes.** En varias variables el vacío tiene significado propio. Por ejemplo, en las opciones de respuesta múltiple (cobertura de salud) vacío quiere decir "no marcó esa opción", y en `bhih01_02` y `imputado` quiere decir "declaró un monto" y "no imputado". Los interpretamos con el diccionario de registros y no los tratamos como nulos.
- **Códigos de no sabe / no contesta (99).** Los sacamos de los análisis, porque no son valores reales.
- **Muestra no proporcional a la población.** Cuando ponderamos con wf1p vimos que las provincias chicas están sobrerrepresentadas. Por eso, cuando queremos hablar de "la población adulta argentina", ponderamos.
- **Los Pasos 2 y 3 los respondió solo una parte.** Las mediciones físicas y bioquímicas existen solo para una submuestra, así que el tamaño de la muestra cae mucho según la variable.

2. Análisis exploratorio de los datos

2.1. Estructura de la base

Lo primero fue ordenar la base. Separamos las variables en dos bloques, el de Hogar y Ubicación (identificación, vivienda, hogar, ingresos, componentes y situación laboral del hogar) y el Individual (datos sociodemográficos, salud general, actividad física, tabaco, hipertensión, peso, alimentación, colesterol, alcohol, diabetes, lesiones, prácticas preventivas, cáncer colorrectal, mediciones antropométricas y bioquímicas, y factores de ponderación). Para cada temática hicimos una función que grafica la variable con el mismo formato: histograma junto con un boxplot para las numéricas y barras con porcentajes para las categóricas .

Dos cosas que se ven enseguida. Primero, casi todas las variables del cuestionario son categóricas codificadas, así que el diccionario de registros fue indispensable para traducir los códigos. Segundo, hay muchos vacíos que vienen del flujo del cuestionario: por ejemplo, las preguntas sobre pastillas para la presión se hacen solo a quienes dicen tener hipertensión.

2.2. Aspectos de interés que elegimos

En vez de analizar las 287 variables una por una, definimos tres objetivos principales para estudiar en profundidad que nos parecieron interesantes y para los que la ENFR es especialmente útil:

- **Representatividad y escala:** ¿la muestra refleja a la población por provincia y por tamaño de ciudad?
- **Hábitos de riesgo:** tabaco, alcohol, alimentación, actividad física y peso.
- **Enfermedades y mediciones objetivas:** hipertensión, diabetes, IMC medido, presión, cintura y glucemia.

2.3. Limpieza de la base

Al principio, comprobamos que los datos recopilados eran consistentes con el diseño de la encuesta. Para no perder información, decidimos no aplicar una limpieza general. En cambio, depuramos los datos según cada hipótesis particular. Esta decisión fue clave porque los pasos 2 y 3 analizan solo una submuestra, y eliminar cualquier fila con datos faltantes nos habría dejado con una muestra demasiado pequeña.

3. Hipótesis y resolución

Todas las hipótesis usamos un **α = 0,05**.

3.1. Hipótesis 1 (nuestra, univariada): la muestra representa a las provincias en proporción a su población

3.1.1. Definición de la hipótesis

Motivación. Antes de sacar conclusiones sobre "los argentinos" tenemos que saber si la muestra es una buena foto del país. La ENFR está pensada para dar resultados por provincia, y eso podría hacer que las provincias chicas pesen más de lo que les toca.

Hipótesis. Todas las provincias están representadas en proporción a la distribución de la población argentina en 2018.

- H0: la proporción de la muestra en cada provincia es igual a su proporción en la población.
- H1: al menos una provincia no está correctamente representada.

3.1.2. Estrategia de abordaje

La población de cada provincia la sacamos de la misma encuesta: el wf1p es el factor de expansión del INDEC y dice a cuántas personas representa cada caso. Al sumarlo por provincia obtuvimos la población proyectada de 18 años o más (unos 27,9 millones en el país). Con eso calculamos los casos esperados y usamos un **test chi-cuadrado de bondad de ajuste**, porque tenemos una sola variable categórica y queremos ver si su distribución coincide con una conocida. Como con casi 30 mil casos cualquier diferencia chica sale significativa, calculamos también la **w de Cohen** (0,1 chica, 0,3 mediana, 0,5 o más grande) y los residuos de Pearson para ver dónde está la diferencia. El cálculo está en las Sec. 2.1.1 y 2.1.2 del código.

3.1.3. Resultados obtenidos y discusión

Rechazamos H0: chi² = 18.376,43 , p < 0,001, y w de Cohen = 0,79 (efecto grande). La muestra no está repartida como la población.

Provincia	% en la muestra	% en la población	Residuo
Buenos Aires	19,07	41,98	−60,45
Ciudad de Buenos Aires	4,69	8,21	−20,97
Córdoba	6,79	8,31	−8,98
Tucumán	3,24	3,23	0,13
Catamarca	2,96	0,72	45,34
Río Negro	4,93	1,54	46,75

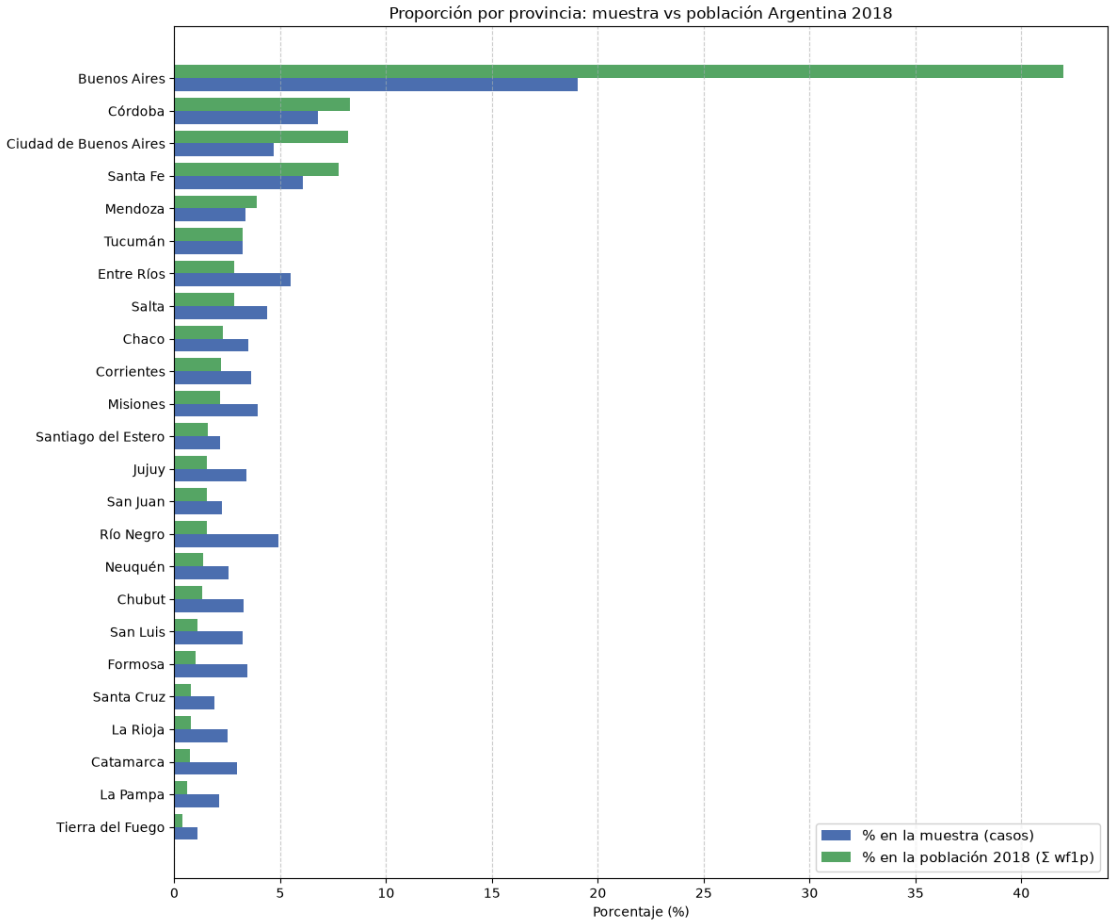


Fig. 3: Porcentaje de casos de cada provincia en la muestra (azul) contra su porcentaje en la población 2018 calculado con la suma de wf1p (verde). Buenos Aires tiene el 19% de los casos y el 42% de la población.

Las provincias grandes tienen menos casos de los que deberían (Buenos Aires, CABA, Santa Fe, Córdoba y Mendoza) y las chicas tienen más: Catamarca, La Pampa, Formosa, La Rioja, Río Negro y San Luis tienen entre 3 y 4 veces los casos esperados. Tucumán es la única que queda casi igual. Tiene sentido: la encuesta le asigna más casos a las provincias chicas para poder dar resultados por provincia. **Consecuencia para el trabajo:** para hablar de toda la población hay que ponderar con wf1p, si no los resultados quedan inclinados hacia las provincias chicas.

Rechazar H0 era esperable, porque la muestra se armó así a propósito: lo que importa del test es el tamaño de la diferencia (w = 0,79) y hacia dónde va.

3.2. Hipótesis 2 (nuestra, bivariada): el tamaño de la ciudad se relaciona con los hábitos nocivos

3.2.1. Definición de la hipótesis

Motivación. Pensamos que la vida en una gran ciudad (estrés, ritmo, oferta de salidas) podría cambiar los hábitos de la gente respecto de las ciudades chicas. Si fuera así, las políticas de prevención deberían ser distintas según la escala de la ciudad.

Hipótesis. El tamaño de la ciudad (aglomerado) se relaciona con los hábitos nocivos para la salud: fumar y el consumo episódico excesivo de alcohol.

- H0: el tamaño del aglomerado y los hábitos nocivos son independientes.
- H1: están asociados, es decir, los hábitos cambian según el tamaño de la ciudad.

3.2.2. Estrategia de abordaje

Armamos un patrón de hábitos con cuatro categorías (ninguno, solo tabaco, solo alcohol excesivo y ambos) a partir de `consumo_tabaco_100` (fumador actual contra el resto) y `consumo_episodico_excesivo`. El tamaño del aglomerado tiene cuatro categorías: más de 1,5 millones de habitantes (que en la práctica es solo Gran Buenos Aires), de 500 mil a 1,5 millones, de 150 mil a 500 mil y menos de 150 mil. Sacamos los casos sin dato y quedaron 29.070. Usamos el **chi-cuadrado de independencia** porque las dos variables son categóricas. Debido a la gran cantidad de datos, el p-valor sale significativo casi siempre, por eso calculamos la **V de Cramér** y los residuos de Pearson. Después repetimos el test para cada hábito por separado y repetimos sin Gran Buenos Aires. No ponderamos con wf1p; la explicación está en 3.2.4. El código está en las Sec. 2.2.1 a 2.2.3.

3.2.3. Resultados obtenidos y discusión

Rechazamos H0: $chi^2 = 69{,}95$ y $p \approx 1{,}6 \times 10^{-11}$. Hay asociación, pero **muy débil**: la V de Cramér da 0,028. El test es significativo sobre todo por el tamaño de la muestra.

Tamaño del aglomerado	Ninguno	Solo tabaco	Solo alcohol excesivo	Ambos
Más de 1,5 M (GBA)	70,1%	16,1%	8,3%	5,5%
500 mil a 1,5 M	68,8%	18,7%	6,9%	5,6%
150 mil a 500 mil	70,9%	16,4%	7,7%	5,0%
Menos de 150 mil	73,1%	16,7%	6,2%	4,1%

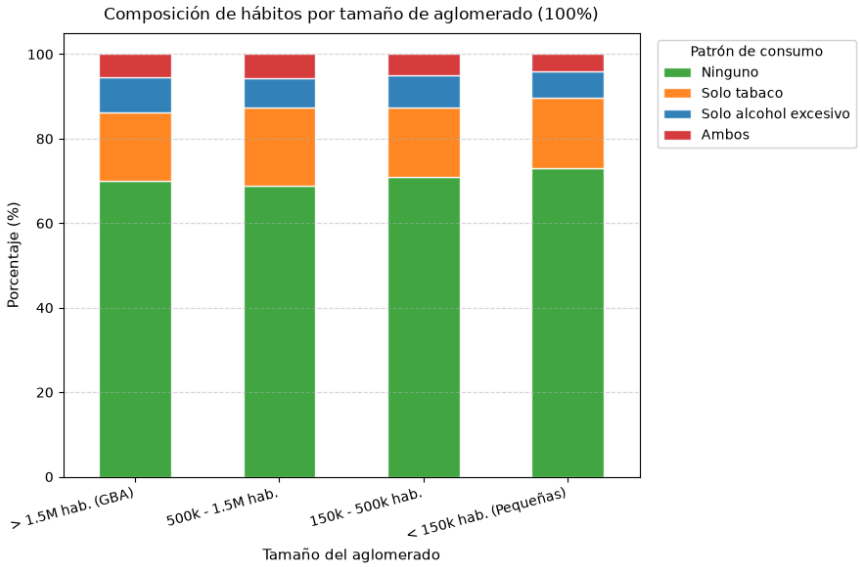


Fig. 4: Composición de los hábitos (ninguno, solo tabaco, solo alcohol excesivo, ambos) según el tamaño del aglomerado, en porcentaje de cada fila. La proporción de personas sin ninguno de los dos hábitos es algo mayor en las ciudades más chicas.

La diferencia está casi toda en el alcohol: los residuos más grandes están en "solo alcohol excesivo" (3,36 en GBA y −3,10 en las ciudades chicas) y en "ambos". Con cada hábito por separado:

- **Alcohol excesivo:** Baja en el orden de 13,8% en GBA a 10,3% en las ciudades de menos de 150 mil habitantes (V de Cramér = 0,043, OR GBA contra ciudades chicas = 1,40).
- **Tabaco:** No sigue el tamaño. Sube a 24,3% en las ciudades de 500 mil a 1,5 millones y queda casi igual en GBA (21,6%) y en las chicas (20,7%) (V = 0,026, OR = 1,05).

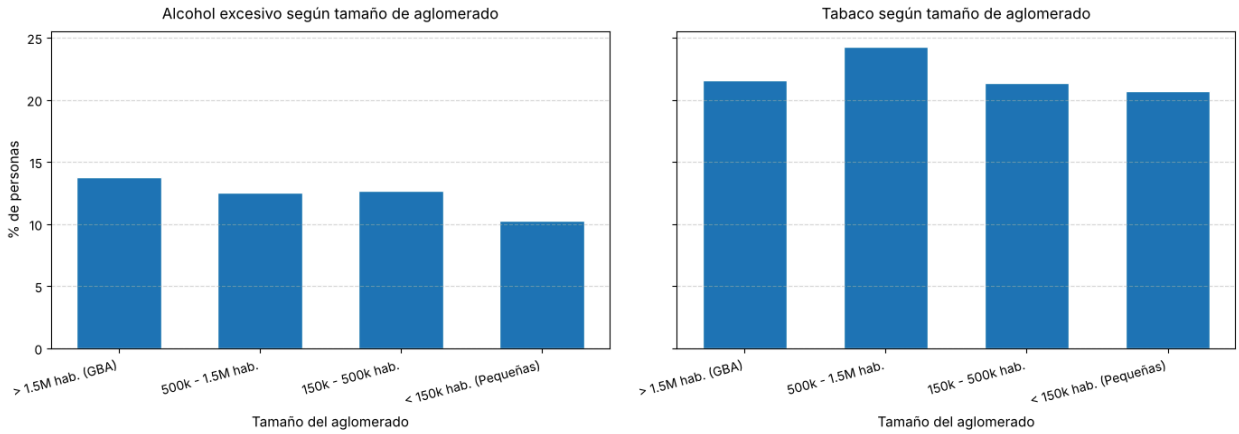


Fig. 5: Porcentaje de personas con consumo episódico excesivo de alcohol (izquierda) y fumadoras (derecha) según el tamaño del aglomerado. Lo que importa es la forma de las barras y no su altura.

Límites que vimos.

- La categoría más grande es solo Gran Buenos Aires, así que "ciudad grande" en realidad es "GBA contra el resto"; sin GBA la asociación sigue (chi² = 47,66; V = 0,031).

- Para ver cuánto depende del indicador, repetimos el test con "tomó alcohol en los últimos 30 días" la asociación es más fuerte (V = 0,079; 56,6% en GBA contra 45,5% en las ciudades chicas; Sec. 2.2.3.2 del código), pero esa variable también incluye el consumo moderado, que no es un hábito nocivo.

3.2.4. Por qué no ponderamos en esta hipótesis

Todos los resultados de esta hipótesis son sin ponderar: cada persona cuenta como un caso. Los pesos wf1p suman unos 27,7 millones de personas en vez de los 29.070 casos, así que, si los usáramos como frecuencias, el chi² quedaría casi mil veces más grande y el p-valor no tendría sentido. Por eso los porcentajes de esta hipótesis describen a las personas encuestadas y no a toda la población adulta, y no extendemos las conclusiones más allá de la muestra. Como vimos en 3.1, la muestra no es proporcional a la población, y esto es una limitación de este análisis.

3.3. Hipótesis 3 (nuestra, multivariada): los hábitos se relacionan con la hipertensión y la diabetes

3.3.1. Definición de la hipótesis

Motivación. La hipertensión y la diabetes son de las enfermedades más comunes y están muy ligadas al estilo de vida. Si los hábitos las explican, tiene sentido enfocar la prevención en ellos.

Hipótesis. Los hábitos (alimentación, actividad física, IMC, alcohol y tabaco) están relacionados con las enfermedades más comunes: hipertensión y diabetes.

- H0: controlando por edad y sexo, ningún hábito está relacionado con tener hipertensión o diabetes (todos sus coeficientes valen 0).
- H1: controlando por edad y sexo, al menos un hábito está relacionado con la enfermedad.

3.3.2. Estrategia de abordaje

Separamos las variables en dos grupos. Las **causas** son el IMC, las porciones de frutas y verduras por día, las horas sentado por día, el nivel de actividad física (contra actividad alta), el tabaco (contra no fumador) y el consumo episódico excesivo de alcohol; la edad y el sexo entran como **controles**. Las **consecuencias** son la hipertensión y la diabetes, que analizamos por separado. Dejamos afuera la glucemia y el colesterol, porque son mediciones del lado de la enfermedad y no hábitos (además la glucemia es parte del diagnóstico de diabetes). Con eso quedaron 23.333 casos completos con prevalencia de 36,7% en hipertensión y 13,9% en diabetes.

Primero hicimos un **UMAP** sobre las causas y la edad, con 3.000 casos al azar, para ver si los hábitos arman grupos (usamos UMAP y no PCA porque capta también relaciones no lineales; Sec. 2.3.2 del código). Como el UMAP no usa la enfermedad, no sirve para probar la hipótesis, así que ajustamos una **regresión logística** por enfermedad (el resultado es sí o no). Separamos 70% entrenamiento (16.333) y 30% prueba (7.000), estandarizando las variables continuas con la media y el desvío del entrenamiento. Después quitamos las variables cuyo IC del 95% contiene al 0 (modelo reducido), revisamos la multicolinealidad con el VIF y, como las clases están desbalanceadas, probamos una versión con errores ponderados y regularización Ridge ($\lambda = 1$). Evaluamos los modelos con el Recall y la Precisión como

métricas principales, y mostramos el Accuracy solo como referencia (la justificación está en 3.3.3). Para probar H0 como bloque comparamos cada modelo con uno que tiene solo edad y sexo. El código está en las Sec. 2.3.1 a 2.3.3.

3.3.3. Resultados obtenidos y discusión

Rechazamos H0: aun controlando por edad y sexo, varios hábitos tienen un IC del 95% que no incluye al 0 y los dos modelos son significativos en conjunto. **Pero no todos los hábitos pesan igual**, y el efecto es modesto. Como bloque, los hábitos mejoran mucho el modelo respecto de uno con solo edad y sexo y también sin contar el IMC, así que el resultado no depende solo del IMC.

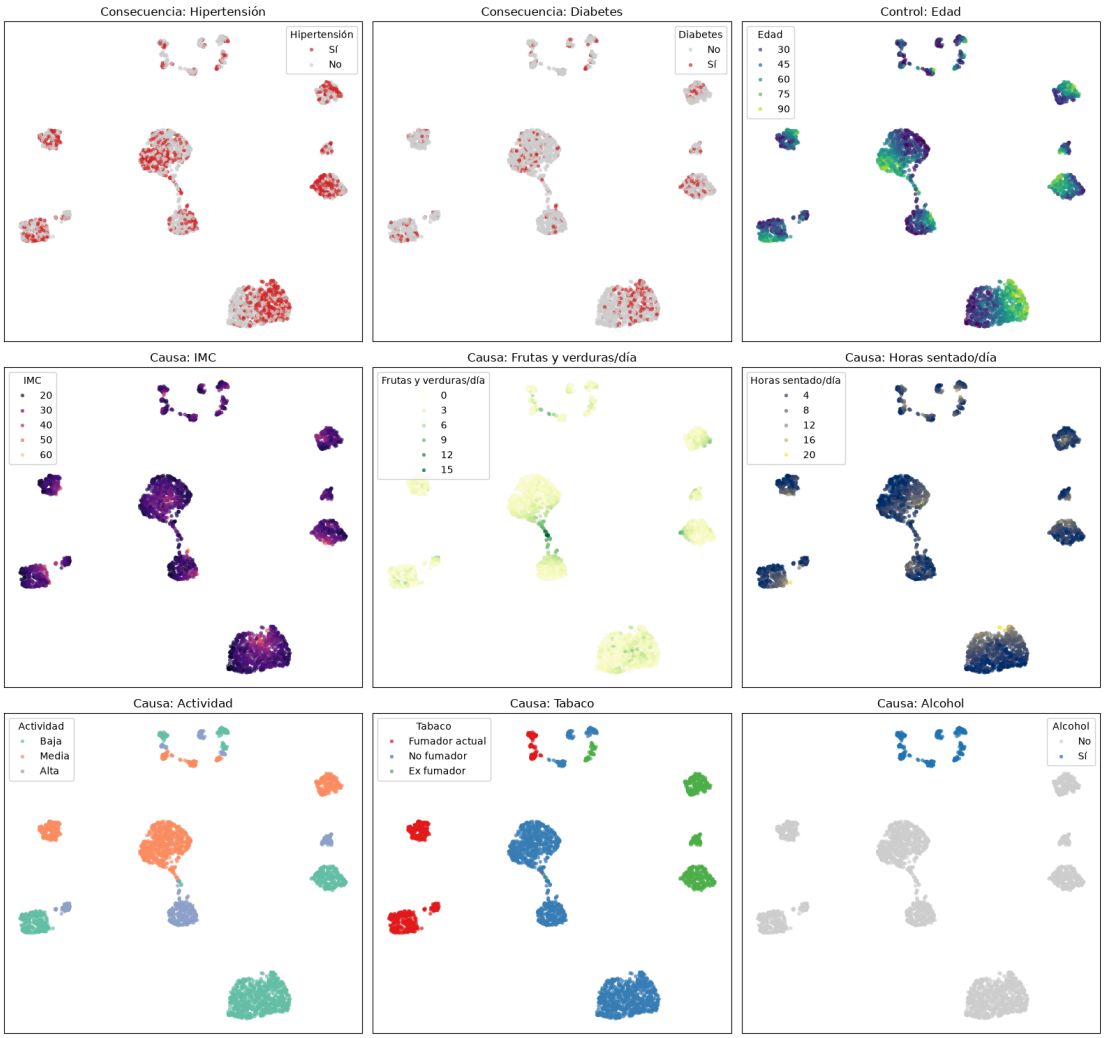


Fig. 6: UMAP de las causas y la edad (3.000 casos). Cada gráfico pinta el mismo mapa con una variable distinta. Las islas son combinaciones de actividad física, tabaco y alcohol; la hipertensión y la diabetes aparecen en todas y se concentran del lado de más edad.

El UMAP muestra que las enfermedades no forman grupos propios: aparecen en todas las islas y se juntan hacia las personas mayores. Eso sugiere que la edad pesa más que cualquier hábito.

Investigando en la web, el odds ratio (OR) dice cuánto cambia la probabilidad de tener la enfermedad cuando cambia un hábito, dejando todo lo demás igual. Logramos gráfica esta métrica y conseguimos los siguientes valores:

Variable	Hipertensión	Diabetes
Edad	2,07	1,50
Mujer	1,22	1,17
IMC	1,54	1,47
Frutas y verduras por día	(queda afuera)	1,05
Horas sentado por día	(queda afuera)	1,07
Alcohol excesivo	(queda afuera)	0,69
Actividad física baja	1,08	1,37
Actividad física media	(queda afuera)	1,34
Ex fumador	1,14	1,17

- **IMC** y **actividad física baja** se asocian con las dos enfermedades. Fumar actualmente no se asocia con ninguna; los ex fumadores sí tienen más chance (hipertensión 1,14 y diabetes 1,17).
- **Frutas y verduras, horas sentado y alcohol**: quedan afuera del modelo de hipertensión, y en diabetes se quedan, pero con resultados mixtos. Son efectos chicos, y el de frutas y verduras tiene un p-valor justo (0,04) y un signo contrario al esperado, así que no los tomamos como firmes. El alcohol excesivo, en cambio, disminuye las probabilidades de contraer diabetes (0,69). Lo más probable es **causalidad inversa**: la encuesta es una foto de un solo momento y quien ya fue diagnosticado suele dejar de fumar y de tomar y empezar a comer mejor. Por eso son asociaciones y no causas.
- **Modelo reducido:** el de hipertensión pasa de 10 a 5 variables con el mismo Pseudo R^2 (0,123) y menor AIC y BIC; el de diabetes solo pierde fumador actual. Nos quedamos con los reducidos por parsimonia.
- **Multicolinealidad:** todos los VIF son menores a 2,2. No revisamos normalidad y homocedasticidad de residuos porque son supuestos de la regresión lineal.
- **Pseudo R^2 bajo:** 0,12 en hipertensión y 0,06 en diabetes. Lo tomamos como una limitación del set de datos y no como un problema del modelo. Los hábitos auto reportados de una encuesta transversal son solo una parte de lo que determina quién se enferma (hay factores que la encuesta no mide, como la genética), y en los modelos logísticos aplicados a salud es habitual que el R^2 sea bajo. Lo que sostiene la conclusión es que los coeficientes son significativos (IC del 95% sin el 0) y que tienen coherencia teórica: más IMC y menos actividad física se asocian con más chance de enfermar. Por eso no ajustamos el modelo para subir el R^2.

En la evaluación con los datos de prueba, el problema fue el desbalance de clases y no el sobreajuste. Por eso comparamos los modelos con el Recall y la Precisión, y mostramos el Accuracy solo como referencia (ver la justificación más abajo):

	Hipertensión, sin ponderar	Hipertensión, Ridge ponderado reducido	Diabetes, sin ponderar	Diabetes, Ridge ponderado reducido
Recall	0,457	0,691	0,009	0,672
Precisión	0,623	0,550	0,529	0,222
Accuracy	0,699	0,679	0,861	0,627
NPV	0,727	0,789	0,862	0,921

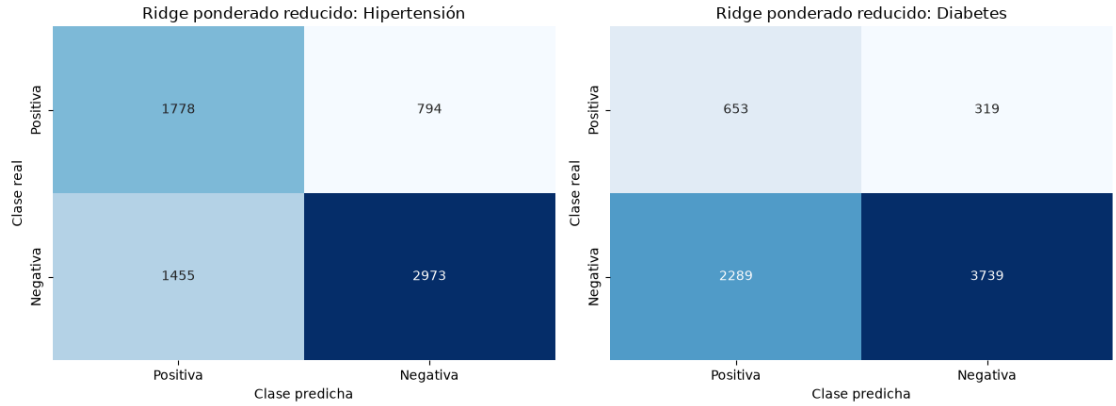


Fig. 7: Matrices de confusión del modelo Ridge ponderado reducido sobre el conjunto de prueba (7.000 casos), para hipertensión (izquierda) y diabetes (derecha). Las filas son la clase real y las columnas la predicha.

Por qué priorizamos el Recall sobre el Accuracy. Con clases desbalanceadas el Accuracy engaña. En diabetes solo el 14% de los casos son positivos, así que un modelo que responda siempre "No" acierta el 86% sin detectar a ningún enfermo. El Logit común saca 0,861, prácticamente lo mismo, y con el Ridge ponderado el Accuracy baja a 0,627 justo cuando el modelo empieza a detectar casos (el Recall pasa de 0,01 a 0,67). Si eligiéramos por Accuracy nos quedaríamos con el peor modelo. Por eso miramos el Recall (de los enfermos reales, cuántos detecta el modelo) y la Precisión (de las personas marcadas como enfermas, cuántas lo están). Priorizamos el Recall porque en una enfermedad como la diabetes un falso negativo cuesta más que un falso positivo: una persona enferma que el modelo deja pasar sigue sin diagnóstico ni tratamiento, mientras que una falsa alarma se descarta con un análisis de confirmación. La Precisión muestra el precio de ese Recall. En la Fig. 7, el Ridge ponderado reducido detecta 653 de los 972 diabéticos del conjunto de prueba y deja pasar 319 (falsos negativos), con 2.289 falsas alarmas. En hipertensión detecta 1.778 de 2.572, deja pasar 794 y tiene 1.455 falsas alarmas.

El Modelo por Accuracy casi siempre predice "No" en diabetes (recall de 0,01) porque solo el 14% es diabético. Ponderando los errores y con Ridge el recall sube a 0,69 en hipertensión y 0,67 en diabetes. El costo son más falsas alarmas: en diabetes la precisión es 0,22, o sea que más o menos 1 de cada 5 personas marcadas es diabética. Es el precio de priorizar el Recall, y lo presentamos como una limitación de lo que se puede predecir con estos datos, no como algo para corregir con más ajustes. **En resumen:** los hábitos sirven para explicar diferencias de riesgo entre grupos, pero no alcanzan para predecir quién está enfermo sin muchas falsas alarmas.

3.4. Hipótesis 4 (cátedra, univariada): el consumo de frutas y verduras es menor a 5 porciones diarias

3.4.1. Definición de la hipótesis

Motivación. La OMS recomienda consumir al menos cinco porciones de frutas y verduras por día. Comer poco de esto se relaciona con más riesgo de enfermedades, así que es un indicador clave de la calidad de la alimentación.

Hipótesis. El consumo diario de frutas y verduras de la población adulta argentina es menor a las 5 porciones diarias.

- H0: el consumo diario promedio es de 5 porciones o más ($\mu \geq 5$).
- H1: el consumo diario promedio es menor a 5 porciones ($\mu < 5$).

3.4.2. Estrategia de abordaje

Usamos `promedio_fv_diario` (28.471 personas). Lo llevamos a escala 0 a 1 con **normalización Min-Max** . Revisamos la normalidad con **Shapiro-Wilk** y un QQ-plot, y aplicamos un **test t de una muestra unilateral**, el mismo planteo del ejemplo de las casas de Boston que vimos en clase, con el teorema central del límite como justificación para usarlo con datos no normales. Por último, repetimos el test ponderando con wf1p, para ver si la conclusión se mantiene al representar a toda la población. Como los pesos son muy distintos entre sí, cada persona aporta distinta cantidad de información, y contar los 28.471 casos como si valieran lo mismo daría un resultado demasiado seguro (con desvío estándar cercano a cero). Por eso usamos el tamaño efectivo de Kish, que estima cuántos casos “valen” de verdad con esos pesos. Está en las Sec. 3.1.1 a 3.1.4 del código

3.4.3. Resultados obtenidos y discusión

Rechazamos H0: el consumo de frutas y verduras de la población adulta argentina es menor a 5 porciones diarias.

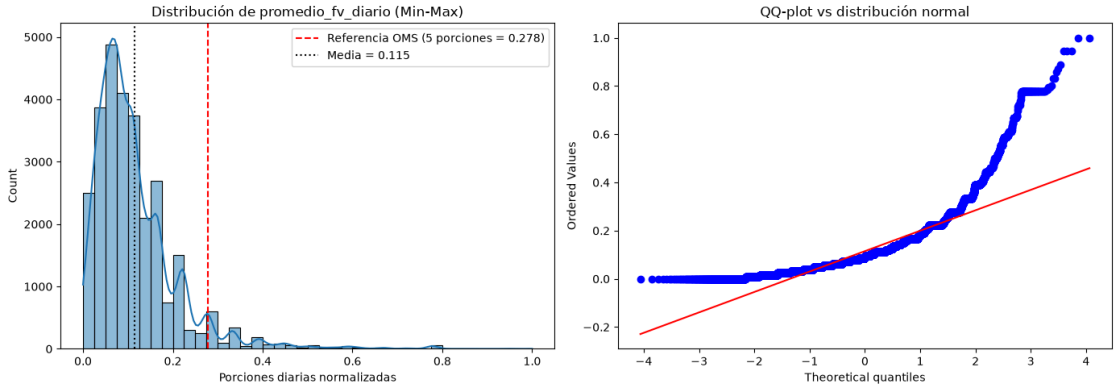


Fig. 8: Distribución de las porciones diarias de frutas y verduras en escala Min-Max (izquierda), con la referencia de la OMS (línea roja) y la media (línea negra), y QQ-plot contra la normal (derecha). La mayoría de la gente queda lejos del umbral.

- **Normalidad:** Shapiro-Wilk rechaza la normalidad ($W = 0{,}797$, $p < 0{,}001$) y la asimetría es 2,55: la mayoría come pocas porciones y unos pocos comen muchas. Aun así el test t es válido, porque con 28 mil casos la media se comporta como normal.
- **Test t:** $t = -289{,}29$ y $p < 0{,}001$. Se comen en promedio 2,07 porciones por día y la cota superior del IC del 95% es 2,09, muy lejos de 5.
- **Ponderado con wf1p:** la media baja a 2,03 porciones, el porcentaje que llega a 5 porciones pasa de 6,2% a 6,0%, el n efectivo cae de 28.471 a unos 8.994 y el t queda en −171. La conclusión no cambia.

En resumen, solo unos 6 de cada 100 adultos llegan a las 5 porciones. Un límite a tener en cuenta es que el dato es autorreportado.

3.5. Hipótesis 5 (cátedra, bivariada): el IMC cambia según el nivel de actividad física

3.5.1. Definición de la hipótesis

Motivación. Se suele pensar que más actividad física se asocia con menor peso. Con el IMC medido evitamos los sesgos del peso y la altura auto reportados.

Hipótesis. El IMC medido cambia según el nivel de actividad física.

- H0: la distribución del IMC es la misma en los tres niveles (alta, media y baja).
- H1: el IMC es distinto en al menos dos niveles. Esperamos que a menor actividad, mayor IMC.

3.5.2. Estrategia de abordaje

La variable respuesta es `imc_bima` (cuantitativa continua, en kg/m²) y la explicativa es `nivel_actividad_fisica` (ordinal con tres niveles). Sacamos a quienes no tienen IMC medido y los códigos 99; quedaron 16.282 personas (2.768 con actividad alta, 5.840 media y 7.674 baja). Para comparar una variable continua entre tres grupos, lo primero que pensamos fue el ANOVA de un factor, que necesita normalidad dentro de cada grupo y varianzas iguales. Lo verificamos con histogramas y QQ-plots, con **Kolmogorov-Smirnov** y con **Levene**. Como no se cumplió ninguno, usamos **Kruskal-Wallis** y comparaciones de a pares con **Mann-Whitney**.

3.5.3. Resultados obtenidos y discusión

Rechazamos H0: el IMC medido cambia según el nivel de actividad física, y tiende a ser más alto cuanto menor es la actividad.

Nivel de actividad	n	Media	Mediana	Varianza
Alta	2.768	26,95	26,15	28,65
Media	5.840	27,83	27,06	30,91
Baja	7.674	28,99	28,23	39,26

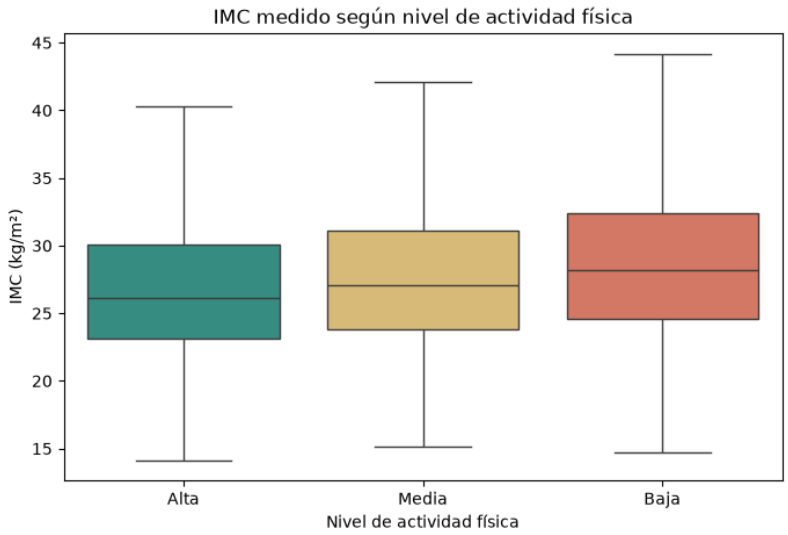


Fig. 9: Boxplot del IMC medido (kg/m²) según nivel de actividad física, sin mostrar los valores extremos. La caja y la mediana suben de alta a baja actividad, pero los grupos se superponen bastante.

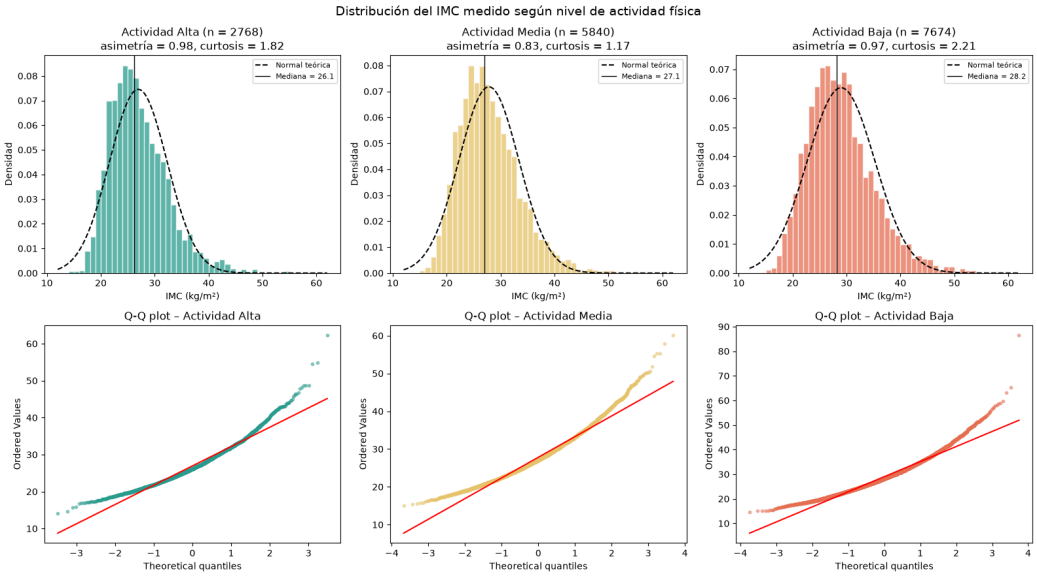


Fig. 10: Histogramas (arriba, con la normal teórica) y QQ-plots (abajo) del IMC en cada nivel de actividad. En los tres la asimetría es cercana a 1 y hay una cola larga hacia los IMC altos, por lo que no son normales.

- **Normalidad:** Kolmogorov-Smirnov rechaza en los tres grupos (D entre 0,059 y 0,068, $p < 0,001$).
- **Homocedasticidad:** Levene rechaza ($W = 43,75$, $p = 1,1 \times 10^{-19}$). La varianza crece al bajar la actividad. No se cumplen los supuestos del ANOVA.
- **Kruskal-Wallis:** $H = 271,83$ y $p \approx 9,4 \times 10^{-60}$. Pero **el efecto es chico**: $\varepsilon^2 = 0,017$, o sea que menos del 2% de la variación del IMC tiene que ver con la actividad.
- **Mann-Whitney de a pares:** Los tres pares dan $p < 0,05$ y el orden de medianas es el esperado: 26,2 < 27,1 < 28,2.

Como las varianzas son distintas, lo leemos como que con menos actividad el IMC tiende a tomar valores más altos, y no estrictamente como una diferencia de medianas.

Límites: es una asociación y no prueba causa; la relación podría ir al revés (un IMC alto puede hacer que alguien se mueva menos)

3.6. Hipótesis 6 (cátedra, multivariada): relación lineal entre IMC, presión sistólica, edad y glucemia en ayunas

3.6.1. Definición de la hipótesis

Motivación. El peso, la cintura, la presión y la edad son factores de riesgo conocidos de la diabetes, así que sería razonable que se reflejan en la glucemia, incluso en personas sin diagnóstico.

Hipótesis. Existe una relación lineal entre el IMC, la presión sistólica y la edad, y la glucemia capilar en ayunas. La cintura la estudiamos en el PCA y en las correlaciones, pero no entra al modelo.

- H0: ninguna de las tres variables tiene relación lineal con la glucemia ($\beta_1 = \beta_2 = \beta_3 = 0$).
- H1: al menos una de las variables tiene relación lineal con la glucemia.

3.6.2. Estrategia de abordaje

Usamos las cinco variables (IMC medido, presión sistólica promedio, cintura, edad y glucemia) y les pusimos nombres cortos. Sacamos a las personas con diagnóstico de diabetes, porque la enfermedad y su tratamiento cambiaron la glucemia y taparon la relación buscada, y también a las 24 que no saben o no contestan si tienen: quedaron 4.286 casos. Sacamos solo los atípicos extremos de las predictoras, los que están a más de 3 veces el IQR (21 casos, quedaron 4.265). Después miramos cuánta información comparten las predictoras con **PCA** (estandarizadas, porque están en unidades distintas), con la **correlación de Pearson** y con un **t-SNE**. Como el IMC y la cintura miden casi lo mismo (correlación 0,82), dejamos afuera la cintura y ajustamos una **regresión lineal múltiple** (OLS) de la glucemia contra IMC, presión sistólica y edad, interpretando el test F global y el test t de cada coeficiente. Al final revisamos los supuestos con **Shapiro-Wilk** sobre los residuos, un gráfico de residuos contra predichos y Breusch-Pagan, que revisa si el error del modelo tiene la misma variabilidad en todos los valores predichos; como la varianza no es constante, repetimos el modelo con errores robustos (HC3) y con los

pesos wf3p. También ajustamos el modelo con las cuatro variables para ver qué pasa con la cintura. Está en las Sec. 3.3.1 a 3.3.5 del código.

3.6.3. Resultados obtenidos y discusión

Rechazamos H0: el IMC y la edad tienen una relación lineal significativa con la glucemia capilar (F = 54,45; p < 0,001), y se mantiene con errores robustos y con pesos. La presión sistólica es el resultado más débil, y la relación en general es débil.

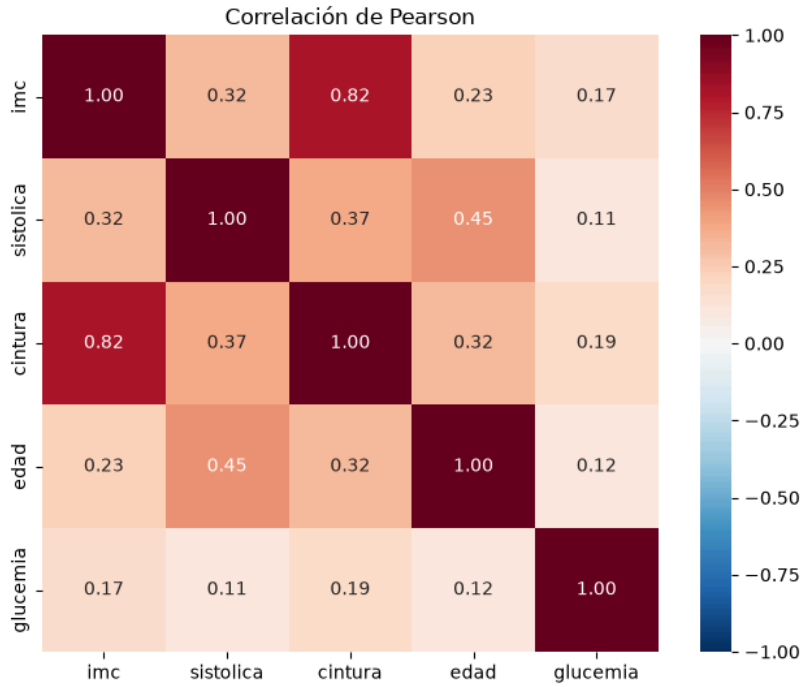


Fig. 11: Matriz de correlaciones de Pearson entre las cuatro predictoras y la glucemia (n = 4.265). Todas las correlaciones con la glucemia son positivas pero débiles (0,11 a 0,19), y IMC y cintura están muy relacionados (0,82).

- **PCA:** las dos primeras componentes juntan el 81,9% de la varianza (57,2% y 24,7%). En la primera, las cuatro variables pesan parecido y en el mismo sentido; la segunda separa a las personas mayores (edad y presión) de las más corpulentas (IMC y cintura).
- **t-SNE:** las personas forman una sola nube y los colores de la glucemia se mezclan por todos lados: perfiles parecidos no tienen glucemias parecidas.
- **Regresión:** el test F da 54,45. La glucemia sube 0,60 mg/dl por cada punto de IMC, 0,087 mg/dl por año de edad y 0,045 mg/dl por mm Hg de presión sistólica (es el resultado más frágil, ver abajo). **Pero el R^2 es 0,037**: el modelo explica menos del 4% de la variación de la glucemia, que depende sobre todo de cosas que no están en el modelo.
- **Cintura:** La dejamos afuera porque mide casi lo mismo que el IMC (correlación de 0,82). Con las cuatro variables el test F también rechaza H0 ($F = 47,0$; $p \approx 9,7 \times 10^{-39}$; $R^2 = 0,042$), pero la cintura sale significativa y el IMC y la presión sistólica dejan de serlo: se reparten la misma información y no se puede separar el efecto de cada una.

- **Supuestos:** Shapiro-Wilk rechaza la normalidad de los residuos ($W = 0{,}927$, $p < 0{,}001$), por la cola de glucemias muy altas. En el gráfico de residuos contra predichos la banda se ve bastante pareja, pero Breusch-Pagan rechaza la varianza constante ($p \approx 6{,}5 \times 10^{-6}$), así que hay algo de heterocedasticidad.

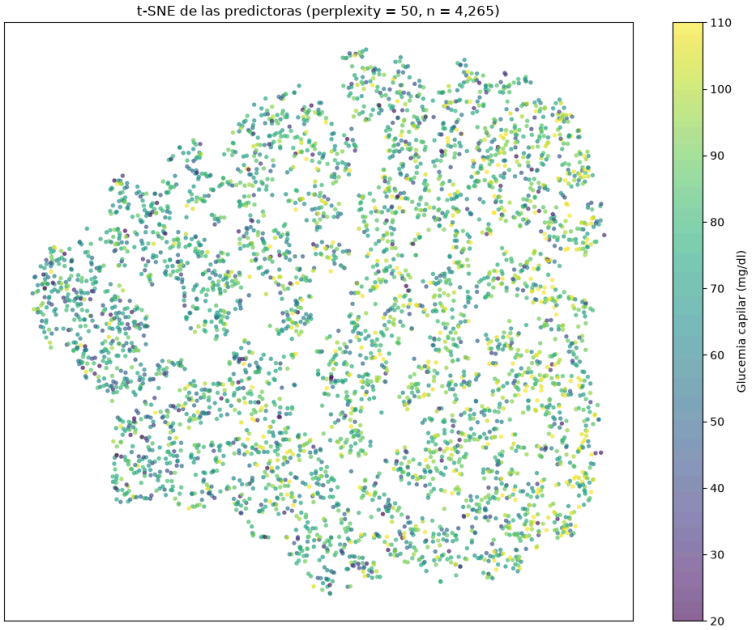


Fig. 12: t-SNE de las cuatro predictoras estandarizadas (perplexity = 50, n = 4.265), con cada punto coloreado por su glucemia. Es una sola nube, sin grupos, y los colores se mezclan en toda ella.

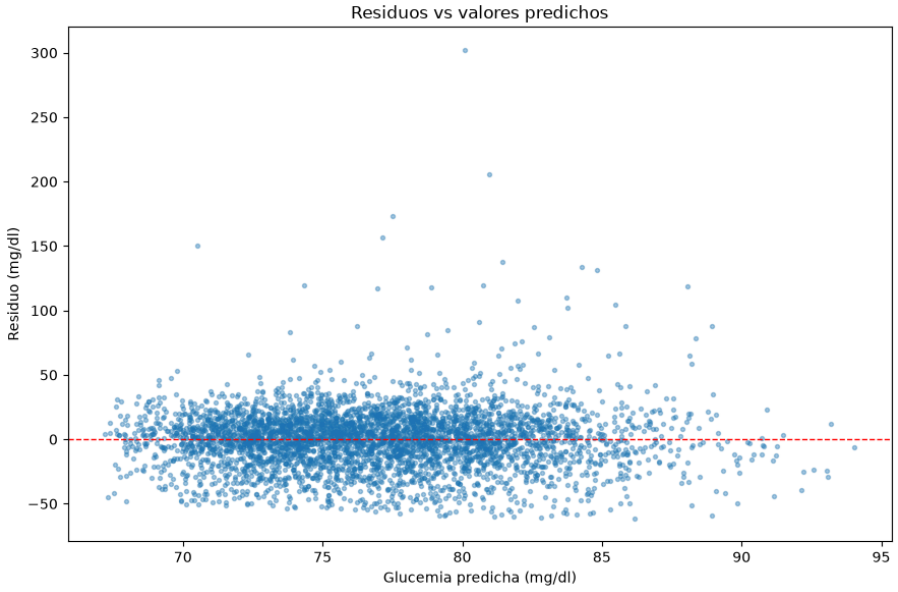


Fig. 13: Residuos contra glucemia predicha (mg/dl) del modelo lineal. La banda se ve bastante pareja alrededor de 0, aunque Breusch-Pagan detecta algo de heterocedasticidad, y hay residuos positivos muy grandes (personas con glucemia mucho más alta que la predicha).

4. Conclusiones

Resumen de lo que encontramos:

Hipótesis	Test	Resultado
3.1 Las provincias están representadas en proporción a la población	Chi² de bondad de ajuste	**Rechazada** (w = 0,79, efecto grande)
3.2 El tamaño de la ciudad se asocia con los hábitos nocivos	Chi² de independencia	**Confirmada, asociación muy débil** (V = 0,028)
3.3 Los hábitos se relacionan con hipertensión y diabetes	Regresión logística	**Confirmada** (Pseudo R^2 0,12 y 0,06) pero haciendo énfasis en el Recall
3.4 El consumo de frutas y verduras es menor a 5 porciones	Test t de una muestra	**Confirmada** (media 2,07; solo 6% llega a 5)
3.5 El IMC cambia con la actividad física	Kruskal-Wallis y Mann-Whitney	**Confirmada, efecto chico** (ε^2 = 0,017)
3.6 Relación lineal entre IMC, presión, edad y glucemia	Regresión lineal múltiple	**Confirmada, relación débil** (R^2 = 0,037); la presión sistólica es el resultado más frágil

Volviendo a lo que planteamos en la introducción, en general los hábitos de riesgo se asocian con peor salud, pero las asociaciones son chicas. Con casi 30 mil casos casi todo sale significativo, así que fue clave mirar también los tamaños del efecto (w de Cohen, V de Cramér, ε^2, R^2) y no quedarnos solo con el p-valor. La edad pesó más que cualquier hábito, tanto en el UMAP como en las regresiones. En términos de hábitos, el dato más fuerte es el de alimentación: apenas 6 de cada 100 adultos llegan a las 5 porciones diarias de frutas y verduras.

Límites. La encuesta es transversal, así que mostramos asociaciones y no causas, y varios resultados "al revés" (ex fumadores, alcohol protector en diabetes) se explican por causalidad inversa. Muchos datos son autorreportados. Las mediciones físicas y bioquímicas existen solo para una submuestra, lo que reduce mucho el n en la hipótesis 3.6.